

Instituto Federal de Educação, Ciência e Tecnologia de São Paulo.

ESP1A5 - Estatística e Probabilidade

Prof. Dra. Josceli M. Tenorio;

Relatório de Análise Estatística, relacionando os indicadores hospitalizações por COVID-19 e a testagem para COVID-19.

Alunos: Matheus Prando Appolinario Barbosa - SP3121747;

João Eduardo Cordeiro de Godoy - SP3123146;

Vitor Da Silva Oliveira - SP3120589;

Guilherme Akio Miura - SP3120791.

INTRODUÇÃO

A pandemia de COVID-19 causou um grande impacto na sociedade em todos os sentidos. Cuidados sanitários, procedimentos de saúde pública e a capacidade hospitalar foram postos à prova no mundo todo. Neste trabalho, analisamos dados de hospitalizações e testagens nos Estados Unidos, buscando entender relações entre testagem, positividade, internações e mortes. Para tal foram utilizadas duas bases de dados, ambas fornecidas pela Our World in Data, um projeto da Global Change Data Lab sem fins lucrativos que tem como objetivo expor pesquisas empíricas e dados analíticos sobre mudanças nas condições de qualidade de vida ao redor do mundo.

BASES DE DADOS UTILIZADAS

Para nossas análises, limitamos as informações apenas ao país dos Estados Unidos, com um agrupamento de dados por data. Foram utilizados os seguintes *datasets*:

Data on COVID-19 (coronavirus) hospitalizations and intensive care:

Uma base de dados extremamente extensa, contando com 135 colunas e 81713 registros para os Estados Unidos. Seu download está disponível [aqui](#). Os dados estão originalmente agrupados de acordo com a data da coleta e o território do país, o seu período de estudo é de 1/1/2020 até 27/4/2024.

A base tem diversas informações muito interessantes a respeito de hospitalizações, internações, níveis de ocupação de hospitais, preparação desses hospitais, quantidade de leitos de UTI evolução da quantidade de casos, contando sempre com a informação (por exemplo, quantidade de leitos de UTI) e quantos hospitais relataram tal dado, à exemplo de:

inpatient_beds com a descrição “*Reported total number of staffed inpatient beds including all overflow and surge/expansion beds used for inpatients (includes all ICU beds) in this state*”, traduzido para “Número total relatado de leitos de internação com equipe, incluindo todos os leitos de sobrecarga e de expansão usados para pacientes internados (inclui todos os leitos de UTI) neste estado”.

inpatient_beds_coverage com a descrição “*Number of hospitals reporting "inpatient_beds" in this state*”, traduzido para “Número de hospitais que relataram “inpatient_beds” neste estado”

COVID-19 testing:

Uma base de dados significativamente menor em colunas, contendo apenas 14, mas a princípio com um número de registros maior, sendo 106789, já que a base foi disponibilizada apenas em sua forma “completa”, sem a filtragem por país. A coleta de dados nos Estados Unidos aconteceu entre os dias 1/3/2020 até 18/06/2022, podendo ser acessada [aqui](#).

Cada linha representa um registro diário para um país específico, contendo informações sobre volume total de testes acumulados, número de testes realizados no dia, média móvel dos testes (7 dias), taxas de positividade (indicando quantos testes deram positivo) e eficiência dos testes (quantos testes por caso detectado). Escolhemos trabalhar com 6 colunas de interesse para os fins dessa análise.

TRATAMENTO DAS BASES DE DADOS

Foram feitas algumas alterações para poder realizar o cruzamento dos dados de uma forma a manter a integridade.

Para a base **Data on COVID-19 (coronavirus) hospitalizations and intensive care**, as seguintes colunas foram selecionadas e tiveram seu nome traduzido

```
"date": "data",
"critical_staffing_shortage_today_yes":
"hospitais_relatarem_estado_critico",
"critical_staffing_shortage_today_no":
"hospitais_relatarem_estado_nao_critico",
"critical_staffing_shortage_anticipated_within_week_yes":
"hospitais_previram_estado_critico",
"critical_staffing_shortage_anticipated_within_week_no":
"hospitais_previram_estado_nao_critico",
"previous_day_admission_adult_covid_confirmed":
"admissões_adultos_covid_confirmado",
"staffed_icu_adult_patients_confirmed_covid":
"pacientes_uti_adultos_covid_confirmado",
"total_pediatric_patients_hospitalized_confirmed_covid":
"internações_pediátricas_covid_confirmado",
"total_staffed_adult_icu_beds":
"total_leitos_uti_disponíveis_adultos",
"deaths_covid": "mortes_covid"
```

Para ter um panorama nacional, foi necessária a eliminação da coluna **"state"**. As demais colunas apenas foram retiradas, já que não são de nosso interesse e não influenciam no agrupamento dos dados.

A chave da tabela então se torna a coluna "date" e os campos remanescentes foram somados, chegando assim ao resultado do número de ocorrências que a coluna dita por cada dia do registro, contendo apenas um dia por registro.

Para a base **COVID-19 Testing**, as seguintes colunas foram selecionadas e tiveram seu nome traduzido

```
"Date": "data",  
"Cumulative total": "total_testes_acumulado",  
"Daily change in cumulative total": "testes_diarios",  
"7-day smoothed daily change": "media_movel_testes_diarios",  
"Short-term positive rate": "taxa_positividade_curto_prazo",  
"Short-term tests per case": "testes_por_caso_curto_prazo"
```

O intervalo utilizado é de 1/3/2020 até 18/06/2022 (dias com registros da base de testagem).

Por fim, realizamos então a junção das bases para uma única (JOIN) chegando a um resultado contendo

```
data,  
hospitais_relatarem_estado_critico,  
hospitais_relatarem_estado_nao_critico,  
hospitais_previram_estado_critico,  
hospitais_previram_estado_nao_critico,  
admissoes_adultos_covid_confirmado,  
pacientes_uti_adultos_covid_confirmado,  
internacoes_pediaticas_covid_confirmado,  
total_leitos_uti_disponiveis_adultos,  
mortes_covid,  
total_testes_acumulado,  
testes_diarios  
media_movel_testes_diarios  
taxa_positividade_curto_prazo  
testes_por_caso_curto_prazo
```

ANÁLISES DE DADOS

Faremos análises ao que da Estatística descritiva, Probabilidade, Inferência das nossas bases


Estatísticas descritivas

É um tipo de análise que busca resumir as características de um conjunto de dados, utilizando tabelas, gráficos e medidas estatísticas, ela fornece resumos simples sobre a amostra e sobre as observações que foram feitas. Vamos destrinchar as principais informações que conseguimos extrair dessa tabela.

- **Mortes por COVID-19**

Infelizmente a pandemia de COVID-19 acometeu muitas pessoas. Com a análise correta dos dados conseguimos entender esse comportamento e tomar ações para evitar que isso aconteça.

- A **média de mortes por dia de vítimas de COVID-19** foi de **801,48**, com um **desvio padrão** de **619.81**
- O **total de mortes por COVID-19** no período foi **673.240**
- A **dia com mais mortes de COVID** aconteceu em **23/05/2020** vitimando **2795** pessoas
- A **média de mortes foi inicialmente ultrapassada** em **2/4/2020**, e a **última vez que foi ultrapassada** foi em **17/02/2022**
- A número de mortes ficou **acima da média** em **361 dias**




No gráfico, existem alguns saltos anômalos, como um pico abrupto no meio de 2020 com mais de 2.700 mortes e uma queda brusca logo depois. Isso pode

indicar atraso ou acúmulo na notificação (registro de vários dias em um só) por parte dos hospitais.

- **Admissões hospitalares de adultos com COVID-19 confirmada**

Para se compreender a lotação de hospitais e a evolução dos casos da COVID-19, acompanhar as admissões hospitalares é de grande valia.


- A **média de admissões hospitalares por dia de vítimas confirmadas de COVID-19** foi de **5.812,21**, com um **desvio padrão** de **4.938,11**
- O **total de admissões** no período foi **4.882.260**
- A **dia com mais admissões de adultos com COVID** aconteceu em **14/1/2022** com **22.451** pessoas
- A **média de admissões** foi inicialmente ultrapassada em **28/7/2020**, e a **última vez que foi ultrapassada** foi em **18/2/2022**
- A número de admissões ficou **acima da média** em **305 dias**



- **Hospitais com estado crítico de lotação**

A superlotação foi um grande problema para a rede de saúde, muitas vezes os hospitais não tiveram a capacidade de atender tantas pessoas, o que leva a um aumento no número de casos mais graves, inclusive casos letais.

- Em **média**, **627.42 hospitais por dia** relataram um **estado crítico de operação**, com um **desvio padrão** de **372.19**
- No dia **24/12/2020**, **1270 hospitais** relataram um **estado crítico**, sendo esse o dia com maior número de hospitais relatando tal estado.



● Total de testes

A testagem é uma arma importantíssima no combate à uma pandemia, pacientes com testes positivos devem mudar totalmente o seu comportamento, buscando não infectar outras pessoas, quando mais pessoas estão cientes de ter a doença mais atitudes podem ser tomadas para conter o contágio e realizar tratamentos

- A **média diária de testes** foi de **1.086.629,91**, com um **desvio padrão de 597.151,46**
- O **total de testes** no período foi **912.769.124**




Gráfico sem a suavização da média móvel





Gráfico sem a suavização da média móvel



Análise dos dados descritivos

É possível perceber eventos importantes com esses gráficos, como a **primeira onda**, ocorrendo por volta de março a junho de 2020, a **segunda onda** de julho a setembro de 2020, a **terceira onda** de outubro de 2020 a fevereiro de 2021, a **quarta onda** causada pela **variante Delta** de junho a novembro de 2021 e a **quinta onda** causada pela variante **Ômicron**, identificada em dezembro de 2021.


Podemos notar que o boom inicial do número de mortes ocorreu antes do boom do número de pacientes hospitalizados, e que após a admissão de pacientes houve inicialmente um alívio nos casos mortais, porém isso levou a um boom da superlotação de hospitais, há após isso uma diminuição do número de hospitalizados. Portanto é perceptível que no início da pandemia os hospitais não estavam prontos para o número repentino de casos que viriam a surgir, muitas pessoas foram hospitalizadas e assim há uma diminuição no número de mortes,

porém hospitais começaram a entrar em níveis críticos de atendimento levando a menos hospitalizações.

Também é possível interpretar que a realização de testes inicialmente não conseguiu acompanhar o número de casos, o que levou a uma menor preparação para as ocorrências de COVID, porém, com o passar do tempo foi percebida a importância da testagem, havendo uma maior ocorrência de testes no período de 1/2022 em relação a 1/2021, sendo assim, mais pessoas que estavam com COVID conseguiram ser hospitalizadas, reduzindo o estresse da rede de saúde e amenizando o número de mortos

Qual a probabilidade de um dia ter alta taxa de positividade E muitos hospitais em estado crítico ao mesmo tempo?

Considerando um piso de 75% de taxa de positividade e 50% para o estado crítico dos hospitais



Baixa positividade + Alto estado crítico: 321 dias

Baixa positividade + Baixo estado crítico: 318 dias

Alta positividade + Baixo estado crítico: 102 dias

Alta positividade + Alto estado crítico: 99 dias

Baixa positividade + Alto estado crítico: 38.21%

Baixa positividade + Baixo estado crítico: 37.86%


Alta positividade + Baixo estado crítico: 12.14%

Alta positividade + Alto estado crítico: 11.79%


Podemos notar que há um **Alto estado crítico** em 50% dos dias e uma **Alta positividade** em 23,93% deles.

Notamos, portanto, que grande parte dos dias (aprox. 76%) estão com baixa positividade nos testes, porém em metade dos dias há uma sobrecarga na rede de hospitais. Isso pode indicar que a positividade dos testes por si não tem uma relação tão forte com a carga alta dos hospitais, mostrando um possível *lag* ou influência de fatores adicionais.

Qual a relação entre o número diário de testes realizados e o número de admissões hospitalares por COVID? Essa relação muda se considerarmos um atraso (lag) nos testes?



Com o uso da correlação de Pearson chegamos a uma correlação entre testes diários e admissões hospitalares sem atraso de dias (o lag) de 0.802, sendo essa uma correlação muito forte entre as variáveis. E para outros dias?



É notável que em 7 dias, 14 dias e 21 dias existe um pico de correlação entre as variáveis. Isso indica um certo delay natural entre o momento da testagem e a internação, pode ser fruto, por exemplo, dos ciclos semanais de evolução da doença uma vez no organismo.

Corroborar, também, com a ideia de que realizar testes pode antecipar a admissão futura de pacientes na rede de saúde, reforçando a utilidade da testagem como ferramenta de monitoramento e previsão de pressão hospitalar futura.

Qual a probabilidade de os hospitais reportarem estado crítico *antes* de um aumento na taxa de positividade?

A ideia é verificar se o estado crítico dos hospitais pode antecipar o aumento da positividade, ou seja, se há uma chance razoável de ter estado crítico hospitalar antes da taxa de positividade subir. Analisando nossas bases, temos que:

$$P(\text{Positividade Alta} \mid \text{Estado Crítico Alto}) = 52.52\%$$

Isso quer dizer: dado que o hospital reportou estado crítico, a chance de a taxa de positividade também estar alta é cerca de 52,5%.

$$P(\text{Positividade Alta} \mid \text{Estado Crítico Baixo}) = 46.52\%$$



Ou seja, se o hospital não está em estado crítico naquele dia, a chance de positividade alta é 46,5%.

Podemos interpretar que a probabilidade de positividade alta é ligeiramente maior quando os hospitais estão em estado crítico no mesmo dia. Porém, essa diferença (52,5% vs 46,5%) é modesta — não é uma disparidade enorme. O lag 0 indica que, no mesmo dia, tanto a taxa de positividade quanto o estado crítico hospitalar estão relacionados. Ou seja, quando a situação nos hospitais piora, a testagem também indica um maior índice de positividade naquele mesmo dia.



Existe uma normalização das variáveis de mortes de COVID, admissões em hospitais e testes diários?

Resultados de testes de análises:


Teste Shapiro-Wilk para mortes_covid: Estatística = 0.9177, p-valor = 0.0000 => Distribuição NÃO é normal
Teste Shapiro-Wilk para mortes_covid transformado (log): Estatística = 0.8330, p-valor = 0.0000
Teste Shapiro-Wilk para mortes_covid transformado (raiz quadrada): Estatística = 0.9893, p-valor = 0.0000



Teste Shapiro-Wilk para admissoes_adultos_covid_confirmado: Estatística = 0.9035, p-valor = 0.0000 => Distribuição NÃO é normal
Teste Shapiro-Wilk para admissoes_adultos_covid_confirmado transformado (log): Estatística = 0.7264, p-valor = 0.0000
Teste Shapiro-Wilk para admissoes_adultos_covid_confirmado transformado (raiz quadrada): Estatística = 0.9649, p-valor = 0.0000



Teste Shapiro-Wilk para testes_diarios: Estatística = 0.9786, p-valor = 0.0000 => Distribuição NÃO é normal
 Teste Shapiro-Wilk para testes_diarios transformado (log): Estatística = 0.6806, p-valor = 0.0000
 Teste Shapiro-Wilk para testes_diarios transformado (raiz quadrada): Estatística = 0.9813, p-valor = 0.0000



Com esses resultados, podemos concluir que mesmo com grandes quantidades de dados, as variáveis **não seguem uma normal clássica**, isso, porém, é esperado para dados epidemiológicos, que frequentemente são assimétricos, com picos, zeros e variações abruptas.

Os hospitais conseguiram prever um futuro estado crítico corretamente?

Realizando o teste de Qui-Quadrado, analisando o p-valor e as probabilidades, temos que:

Lag (dias)	Qui-quadrado (Chi²)	p-valor	P(Estado Crítico Real Alto Previsão Alta)	P(Estado Crítico Real Alto Previsão Baixa)
0	469.51	4.10×10^{-104}	87.59%	12.59%
1	462.61	1.30×10^{-102}	87.35%	12.86%
2	455.76	4.03×10^{-101}	87.11%	13.13%
3	448.95	1.22×10^{-99}	86.87%	13.40%
4	442.18	3.63×10^{-98}	86.63%	13.67%
5	435.46	1.06×10^{-96}	86.40%	13.94%
6	428.77	3.01×10^{-95}	86.16%	14.22%
7	428.77	8.38×10^{-94}	85.92%	14.49%
8	415.54	2.29×10^{-92}	85.68%	14.77%
9	408.98	6.10×10^{-91}	85.44%	15.05%

10	402.47	1.59×10^{-89}	85.20%	15.33%
11	396.01	4.08×10^{-88}	84.96%	15.61%
12	389.58	1.02×10^{-86}	84.73%	15.89%
13	383.20	2.50×10^{-85}	84.49%	16.18%
14	376.87	5.99×10^{-84}	84.25%	16.46%

Percebemos que a probabilidade de ocorrência do estado crítico real dado uma previsão alta é alta (entre ~84% e ~88%) e o caso de erro, ou seja quando há um estado crítico real dado previsão baixa é relativamente baixa (entre ~12% e ~16%), mostrando que a previsão também é útil para identificar períodos menos críticos. Sendo assim a maior parte dos casos de previsão de aumento de estado crítico dos hospitais se concretizaram.

Saber que acontecerá um aumento no número de pessoas necessitando de hospitais possivelmente leva esses hospitais a se prepararem para a maior carga que está iminente, levando assim a um estresse menor e uma melhor previsão de compra de materiais, necessidade de médicos, o que pode refletir num atendimento melhor.

Existe algum impacto da Previsão Antecipada de Estado Crítico Hospitalar nas Mortes por COVID-19 (lag de 7 dias)?

Essa análise tem como objetivo verificar se hospitais que previram com antecedência um estado crítico de lotação apresentaram, nos dias seguintes, menor número de mortes por COVID, sugerindo uma resposta mais eficaz.

Metodologia:

Foram comparados dois grupos:

Grupo A: dias em que houve previsão antecipada de estado crítico.

Grupo B: dias em que não houve previsão.

As mortes foram analisadas com lag de 7 dias (mortes em $t+7$).

Foi aplicado o teste de Mann-Whitney U para verificar se há diferença estatística significativa entre os grupos.

Resultados:

Análise com lag de 7 dias entre previsão e mortes:

Média de mortes (após previsão): 2727.00

Média de mortes (sem previsão): 730.99

Teste de Mann-Whitney U: estatística = 66.00, p-valor = 0.1030

Sem evidência de diferença significativa ($p \geq 0.05$)

Conclusão:

Isso indica que não há evidência estatística suficiente para afirmar que as médias de mortes entre os dois grupos são diferentes, ou seja, não podemos concluir que a previsão de estado crítico leva a uma redução significativa no número de mortes após 7 dias. Porém isso não necessariamente significa que não há uma correlação entre a previsão de nível crítico com o número de mortes, já que pode significar também que os dias com previsão coincidam com picos reais de mortalidade e o efeito dessa previsão (por exemplo, ações tomadas para mitigar mortes) não foi suficiente para alterar estatisticamente o número de óbitos.